

MVP - Data Engineering
Análise Financeira de Filmes TMDb
Implementação de Data Lakehouse com Arquitetura Medallion

Aluno: Gabriela Oliveira Abi Chahin de Lima Gonçalves

Sprint: Engenharia de Dados

Sumário

Contextualização e objetivos gerais	2
Detalhamento do projeto	2
Dados e ferramentas selecionadas	2
Fonte de dados	2
Ferramentas utilizadas	3
Camada Bronze: coleta e carregamento de dados	3
Camada Silver: transformação dos dados	4
Camada Gold: modelagem dos dados	5
Modelo relacional	7
Catálogo de dados	8
Qualidade de dados	10
Solução do problema proposto	11
Pergunta 1 - Quais gêneros possuem maior volume de filmes?	12
Pergunta 2 - Quais gêneros apresentam maior faturamento médio?	12
Pergunta 3 - Quais gêneros apresentam maior lucro médio?	13
Pergunta 4 - Quais gêneros apresentam maior ROI médio?	13
Pergunta 5 - Como a participação dos gêneros evoluiu ao longo dos anos?	14
Análises sobre o dataset	15
Quantidade de gêneros por filme	15
Combinações de gêneros	16
Considerações finais	18
Pontos de melhoria	18
Autoavaliação	18

Contextualização e objetivos gerais

A indústria cinematográfica movimenta bilhões de dólares anualmente e gera grandes volumes de dados relacionados a produção, orçamento, faturamento e desempenho comercial dos filmes. A disponibilidade de bases públicas como a TMDb (The Movie Database) permite a construção de soluções analíticas capazes de identificar padrões de mercado e fatores associados ao sucesso financeiro das produções.

Neste contexto, o objetivo deste projeto é desenvolver um pipeline completo de engenharia de dados utilizando a arquitetura Medallion (Bronze, Silver e Gold), contemplando desde a ingestão dos dados até a disponibilização de estruturas analíticas para apoio à tomada de decisão. O projeto utiliza informações financeiras de filmes lançados entre os anos de 2000 e 2025 e busca responder às seguintes questões:

1. Quais gêneros possuem maior volume de filmes?
 2. Quais gêneros apresentam maior faturamento médio?
 3. Quais gêneros apresentam maior lucro médio?
 4. Quais gêneros apresentam maior ROI médio?
 5. Como a participação dos gêneros na produção cinematográfica evoluiu ao longo do tempo?
-

Detalhamento do projeto

Dados e ferramentas selecionadas

O projeto foi implementado integralmente na plataforma Databricks utilizando Unity Catalog, Spark SQL e PySpark para construção do pipeline de dados. Foram ainda utilizadas bibliotecas auxiliares para análise e visualização dos resultados.

Fonte de dados

TMDb Movies Dataset

Base de filmes contendo informações como:

- Identificador do filme
- Data de lançamento
- Orçamento
- Receita
- Gêneros
- Idioma original

- Popularidade
- Avaliações
- Quantidade de votos

O período de análise compreende produções lançadas entre 2000 e 2025.

Ferramentas utilizadas

- Databricks Community Edition
 - Unity Catalog
 - PySpark
 - Spark SQL
 - Pandas
 - Plotly Express
 - Plotly Graph Objects
-

Camada Bronze: coleta e carregamento de dados

O processo de coleta iniciou-se pela leitura do arquivo CSV disponibilizado no ambiente Databricks através do Volume responsável pelo armazenamento dos dados.

Após a leitura do arquivo, os dados foram armazenados na camada Bronze através da criação da tabela `bronze_movies`.

A camada Bronze foi concebida para armazenar os dados em seu formato bruto, preservando histórico de alterações e possibilitando auditoria através do mecanismo de versionamento do Delta Lake.

Figura 1 – Estrutura da camada Bronze.



```
▶ 3 days ago (2s) 5: Leitura do CSV de Filmes

# Parâmetros:
# - header=True: Primeira linha contém os nomes das colunas
# - sep=',': Separador de campos é vírgula
# - escape='\"': Caractere de escape para campos com vírgula dentro

movies = spark.read.csv('/Volumes/mvp_puc/default/tmdb/movies.csv', header=True, sep=',', escape='\"')

> movies: pyspark.sql.connect.dataframe.DataFrame = [id: string, title: string ... 20 more fields]

▶ 3 days ago (9s) 6: Salvar Tabela Bronze

movies.write.saveAsTable('bronze_movies', mode='overwrite')

> See performance (1) ✓ Checked for improvements
```

Camada Silver: transformação dos dados

Após a ingestão dos dados na camada Bronze, foram executadas etapas de tratamento e padronização para construção da camada Silver.

Os principais tratamentos realizados foram:

- Seleção das colunas relevantes para análise
- Conversão dos tipos de dados
- Padronização das datas
- Filtragem de registros inválidos
- Criação dos atributos temporais ano e mês
- Ordenação cronológica dos registros

Figura 2 – Transformações da camada Silver.

```
movies_selected = movies.select("id", "release_date", "budget", "revenue", "genres")

# 1. Conversão Inicial e Tratamento de Dados Numéricos
# Remove IDs inválidos (que não podem ser convertidos para inteiro)
df_elegivel = movies_selected.filter(F.col('id').try_cast('int').isNotNull()) \
    .withColumn('budget', F.col('budget').cast('double')) \
    .withColumn('revenue', F.col('revenue').cast('double'))

# 2. Tratamento de Datas
# Converte a coluna release_date para o tipo DATE
df_elegivel = df_elegivel.withColumn('release_date', F.to_date(F.col('release_date')))

# 3. Aplicação de Filtros de Elegibilidade
# Mantém apenas filmes com dados financeiros válidos e data de lançamento
df_filtered = df_elegivel.filter(
    (F.col('revenue') > 0) &          # Faturamento positivo
    (F.col('budget') > 0) &          # Orçamento positivo
    (F.col('release_date').isNotNull()) # Data de lançamento presente
)

# 4. Criação de Colunas Temporais
# Extrai ano e mês da data de lançamento para facilitar análises temporais
df_filtered = df_filtered \
    .withColumn('year', F.year(F.col('release_date'))) \
    .withColumn('month', F.month(F.col('release_date')))

# Filtra apenas filmes lançados entre 2000 e 2025
# Este período foi escolhido para focar em produções da mesma geração
df_filtered = df_filtered.filter(
    (F.col('year') >= 2000) & (F.col('year') <= 2025)
)
```

Camada Gold: modelagem dos dados

A camada Gold foi implementada utilizando modelagem dimensional Star Schema.

Foram construídas três tabelas principais:

1. gold_fact_movie_finance

Tabela fato contendo métricas financeiras.

Campos:


- movie_id
- release_date
- budget
- revenue
- profit
- roi

Cálculos:

profit = revenue - budget

roi = revenue / budget

Figura 3 – Tabela fato gold_fact_movie_finance.



```
# Tabela fato contendo métricas financeiras dos filmes.
# Inclui cálculos de:
# - Profit (Lucro): Diferença entre receita e orçamento
# - ROI (Return on Investment): Retorno sobre investimento (receita / orçamento)

fact_movie_finance = df_filtered.select(F.col('id').alias('movie_id'), 'release_date', 'budget', 'revenue') \
    .withColumn('profit', F.col('revenue') - F.col('budget')) \
    .withColumn('roi', F.col('revenue') / F.col('budget'))
fact_movie_finance.show(5)
```

fact_movie_finance: pyspark.sql.connect.dataframe.DataFrame = [movie_id: string, release_date: date ... 4 more fields]

movie_id	release_date	budget	revenue	profit	roi
1359	2000-01-21	7000000.0	3.4269748E7	2.7269748E7	4.895678285714285
47816	2000-03-01	6000000.0	9000000.0	3000000.0	1.5
25212	2000-03-10	800000.0	145071.0	-654929.0	0.18133875
9532	2000-03-17	2.3E7	1.12880294E8	8.9880294E7	4.907838869565217
462	2000-03-17	5.2E7	2.56271286E8	2.04271286E8	4.928293961538461

only showing top 5 rows

2. gold_dim_genres

Tabela dimensional responsável pela representação dos gêneros.

Implementada através da explosão da coluna genres para permitir relacionamento N:N entre filmes e gêneros.

Figura 4 – Tabela dimensional gold_dim_genres.



```
16: Dimensão de Gêneros

# Transforma a coluna de gêneros (formato CSV) em registros individuais.
# Cada filme pode ter múltiplos gêneros, resultando em várias linhas por filme.

# Divide a string de gêneros separada por vírgula em um array
split_genre = df_filtered.select(F.col('id').alias('movie_id'),'genres').withColumn('genres', F.split(F.col('genres'), ','))

# Explode o array, criando uma linha para cada gênero de cada filme
dim_genres = split_genre.select('movie_id','genres').withColumn('genres', F.explode(F.col('genres')))
dim_genres.show(5)
```

> [See performance \(1\)](#) ✓ Checked for improvements

> 2 dataframes: dim_genres, split_genre

movie_id	genres
1359	Drama
1359	Thriller
1359	Crime
47816	Action
47816	Comedy

only showing top 5 rows

3. gold_dim_date

Tabela dimensional de datas.

Campos:

- release_date
- year
- month
- month_name

Os meses foram padronizados para português.

Figura 5 – Tabela dimensional gold_dim_date.

```
19: Dimensão de Data

# Tabela dimensional contendo informações sobre datas de lançamento.
# Facilita análises temporais ao fornecer atributos de data pré-calculados.

# Cria um mapeamento de número do mês para nome abreviado em português
month_mapping = F.create_map(
    F.lit(1), F.lit('Jan'), F.lit(2), F.lit('Fev'), F.lit(3), F.lit('Mar'),
    F.lit(4), F.lit('Abr'), F.lit(5), F.lit('Mai'), F.lit(6), F.lit('Jun'),
    F.lit(7), F.lit('Jul'), F.lit(8), F.lit('Ago'), F.lit(9), F.lit('Set'),
    F.lit(10), F.lit('Out'), F.lit(11), F.lit('Nov'), F.lit(12), F.lit('Dez')
)

# Cria a dimensão com datas únicas e seus atributos
dim_date = df_filtered.select('release_date', 'year', 'month').distinct() \
    .withColumn('month_name', month_mapping[F.col('month')])
dim_date.show(5)

> See performance (1) ✓ Checked for improvements

> dim_date: pyspark.sql.connect.dataframe.DataFrame = [release_date: date, year: integer ... 2 more fields]

+-----+-----+-----+-----+
|release_date|year|month|month_name|
+-----+-----+-----+-----+
| 2003-05-30|2003| 5|    Mai|
| 2000-09-01|2000| 9|    Set|
| 2005-10-26|2005|10|    Out|
| 2007-05-19|2007| 5|    Mai|
| 2002-05-24|2002| 5|    Mai|
+-----+-----+-----+-----+
only showing top 5 rows
```

Modelo relacional

A criação das chaves primárias e estrangeiras e dos relacionamentos foram realizados pelo Databricks, podendo observar o diagrama pelo Catálogo.

Figura 6 – Adicionando chaves primárias.

```
-- 1. Chave primária na tabela fato (um registro por filme)
ALTER TABLE mvp_puc.default.gold_fact_movie_finance
    ADD CONSTRAINT pk_gold_fact_movie_finance PRIMARY KEY (movie_id);


-- 2. Chave primária na dimensão de data (uma data distinta por linha)
ALTER TABLE mvp_puc.default.gold_dim_date
    ADD CONSTRAINT pk_gold_dim_date PRIMARY KEY (release_date);

-- 3. Chave primária composta na dimensão de gêneros (movie_id + genres)
ALTER TABLE mvp_puc.default.gold_dim_genres
    ADD CONSTRAINT pk_gold_dim_genres PRIMARY KEY (movie_id, genres);

-- 4. FK: dim_genres.movie_id -> fact_movie_finance.movie_id
ALTER TABLE mvp_puc.default.gold_dim_genres
    ADD CONSTRAINT fk_dim_genres_fact_movie_finance
    FOREIGN KEY (movie_id) REFERENCES mvp_puc.default.gold_fact_movie_finance(movie_id);

-- 5. FK: fact_movie_finance.release_date -> dim_date.release_date
ALTER TABLE mvp_puc.default.gold_fact_movie_finance
    ADD CONSTRAINT fk_fact_movie_finance_dim_date
    FOREIGN KEY (release_date) REFERENCES mvp_puc.default.gold_dim_date(release_date);
```

Figura 7 – Diagrama Star Schema.



Catálogo de dados

1. gold_fact_movie_finance

Figura 8 – Catálogo da tabela gold_fact_movie_finance.

Description

A tabela fornece informações financeiras sobre filmes. Os dados incluem o orçamento, a receita, o lucro e o retorno sobre o investimento (ROI) para cada filme, além da data de lançamento. Exemplos de uso incluem análise de desempenho financeiro de filmes, comparação de orçamentos e receitas, e avaliação de eficiência de investimentos no setor cinematográfico.

Filter columns...

View relationships

Column	Type	Comment
movie_id	string	Identificador único do filme, utilizado para referenciar cada filme de forma distinta na tabela.
release_date	date	Data de lançamento nos cinemas (formato AAAA-MM-DD)
budget	double	Orçamento de produção em USD
revenue	double	Receita de bilheteria em USD
profit	double	Lucro obtido com o filme, calculado como a diferença entre a receita e o orçamento.
roi	double	Retorno sobre o investimento, calculado a divisão da receita pelo orçamento.

2. gold_dim_genres

Figura 9 – Catálogo da tabela gold_dim_genres.

Description 

A tabela contém informações sobre os gêneros de filmes, associando cada filme a seus respectivos gêneros. Isso pode ser usado para categorizar filmes em análises, entender preferências de público e auxiliar na recomendação de filmes com base em gêneros.

Column	Type	Comment	
movie_id  	string	Identificador único do filme	
genres 	string	Lista de gêneros associados ao filme	

Domínios identificados:

- Drama
- Thriller
- Crime
- Action
- Comedy
- Romance
- Mystery
- Music
- Horror
- Adventure

e demais gêneros presentes na base.

3. gold_dim_date

Figura 10 – Catálogo da tabela gold_dim_date.

Description 

A tabela contém informações sobre datas, incluindo detalhes como ano, mês e nome do mês. Esse conjunto de dados pode ser utilizado para análises temporais, segmentação de dados por períodos ou para relacionar outras informações baseadas em datas.

Column	Type	Comment	
release_date 	date	Data de lançamento nos cinemas (formato AAAA-MM-DD)	
year	int	Ano extraído de release_date, formato YYYY.	
month	int	Mês extraído de release_date, de 1-12	
month_name	string	O nome do mês fornece a designação textual do mês correspondente à data.	

Qualidade de dados

Foi criada uma função denominada `data_quality_report()` que realiza avaliação do dataset.

As métricas calculadas foram:

- Número de registros
- Valores nulos
- Valores vazios
- Valores distintos
- Percentual de ausência dos dados

Figura 11 – Perfil de qualidade de dados.

	dataset	column	data_type	total_rows	null_count	blank_count	missing_count	missing_pct	distinct_count
1	movies	id	StringType0	9778	0	0	0	0	9778
2	movies	title	StringType0	9778	0	0	0	0	9163
3	movies	original_title	StringType0	9778	0	0	0	0	9236
4	movies	overview	StringType0	9778	160	0	160	1.64	9607
5	movies	release_date	StringType0	9778	68	0	68	0.7	6513
6	movies	runtime	StringType0	9778	8	0	8	0.08	235
7	movies	budget	StringType0	9778	8	0	8	0.08	652
8	movies	revenue	StringType0	9778	8	0	8	0.08	3857
9	movies	vote_average	StringType0	9778	8	0	8	0.08	2659
10	movies	vote_count	StringType0	9778	9	0	9	0.09	3114
11	movies	popularity	StringType0	9778	8	0	8	0.08	8722
12	movies	poster_path	StringType0	9778	348	0	348	3.56	9431
13	movies	backdrop_path	StringType0	9778	1525	0	1525	15.6	8254
14	movies	status	StringType0	9778	9	0	9	0.09	11
15	movies	tagline	StringType0	9778	3806	0	3806	38.92	5938
16	movies	homepage	StringType0	9778	6338	1	6339	64.83	3402
17	movies	original_language	StringType0	9778	9	0	9	0.09	75
18	movies	adult	StringType0	9778	9	0	9	0.09	7
19	movies	video	StringType0	9778	8	0	8	0.08	9
20	movies	created_at	StringType0	9778	14	0	14	0.14	9765
21	movies	updated_at	StringType0	9778	15	0	15	0.15	9764
22	movies	genres	StringType0	9778	280	0	280	2.86	917

Solução do problema proposto

Para responder às perguntas de negócio foi criada uma tabela analítica denominada gold_genre_analysis, resultado da junção entre:

- gold_fact_movie_finance
- gold_dim_genres
- gold_dim_date

Figura 12 – Construção da tabela gold_genre_analysis.

```

27: View Analítica de Gêneros

# Combina a tabela fato com as dimensões de gêneros e data.
# Esta view consolida todas as informações necessárias para análises financeiras por gênero ao longo do tempo.
# Serve como base para todas as análises e visualizações subsequentes.
genre_analysis = (
    fact_movie_finance.alias("f")
    .join(
        dim_genres.alias("g"),
        'movie_id',
        "inner"
    )
    .join(
        dim_date.alias("d"),
        F.col("f.release_date") == F.col("d.release_date"),
        "left"
    )
    .select(
        F.col("f.movie_id"),
        F.col("g.genres"),
        F.col("f.budget"),
        F.col("f.revenue"),
        F.col("f.profit"),
        F.col("f.roi"),
        F.col("d.year")
    )
)


> genre_analysis: pyspark.sql.connect.dataframe.DataFrame = [movie_id: string, genres: string ... 5 more fields]

```

Pergunta 1 - Quais gêneros possuem maior volume de filmes?

Foi realizada agregação utilizando countDistinct(movie_id) por gênero.

Figura 13 – Quantidade de filmes por gênero.




Conclusão

De forma geral, os resultados indicam que Drama, Comedy e Action são os gêneros mais recorrentes no conjunto de dados (37,8% do todo), enquanto uma parcela menor dos gêneros concentra um número reduzido de filmes. Essa distribuição pode ser utilizada como ponto de partida para investigar se a maior frequência de determinados gêneros também está associada a diferenças de faturamento, orçamento, lucro ou ROI.

Pergunta 2 - Quais gêneros apresentam maior faturamento médio?

Foi calculada avg(revenue) agrupada por gênero.

Figura 14 – Faturamento médio por gênero.



Conclusão

O gráfico mostra uma diferença importante entre o volume de produção e o faturamento médio por gênero. Embora Drama seja o gênero com maior quantidade de filmes, apresenta faturamento médio de aproximadamente US\$ 102 milhões, ficando abaixo de gêneros como Adventure, Animation e Science Fiction. Além disso, esses três gêneros


também apresentam as maiores médias de orçamento, sugerindo uma possível relação positiva entre o nível de investimento e o faturamento.

Dessa forma, observa-se que uma maior quantidade de filmes não implica necessariamente maior faturamento médio. Os resultados indicam diferenças relevantes no desempenho financeiro entre os gêneros e reforçam a importância de analisar conjuntamente orçamento, faturamento e ROI, permitindo avaliar se os gêneros com maior receita também apresentam maior retorno proporcional sobre o investimento.

Pergunta 3 - Quais gêneros apresentam maior lucro médio?

Foi calculada avg(profit) por gênero.

Figura 15 – Lucro médio por gênero.




Conclusão

Analisando o lucro médio por gênero, observa-se que o Top 5 permanece composto pelos mesmos gêneros identificados nas análises anteriores, indicando que esses gêneros apresentam não apenas maior faturamento, mas também maior capacidade de geração de lucro médio. Esse resultado sugere maior solidez no retorno financeiro das produções desses gêneros.

Pergunta 4 - Quais gêneros apresentam maior ROI médio?

Foi calculada a média de roi para cada gênero.

Figura 16 – ROI médio por gênero.



Conclusão

O gráfico de ROI médio por gênero evidencia diferenças significativas na eficiência financeira dos investimentos realizados na indústria cinematográfica. Observa-se que os gêneros Mystery e Horror apresentam os maiores retornos médios sobre o investimento, com aproximadamente 62,9x e 48,6x, respectivamente, valores muito superiores aos demais gêneros analisados. Por outro lado, gêneros tradicionalmente associados a grandes produções, como Adventure (8,8x) e Animation (4,4x) apresentam ROI médio inferior, apesar de frequentemente registrarem altos níveis de arrecadação. Esse resultado indica que elevados níveis de faturamento não necessariamente se traduzem em maior retorno proporcional sobre o investimento, uma vez que alguns gêneros demandam orçamentos significativamente mais altos para sua produção. Dessa forma, o ROI complementa a análise de faturamento ao permitir avaliar a eficiência financeira dos investimentos realizados.


Pergunta 5 - Como a participação dos gêneros evoluiu ao longo dos anos?

Foi criada uma visualização contendo os três gêneros mais produzidos por ano.

Figura 17 – Window function.

```
# Aplica o ranking e filtra apenas os top 3 de cada ano
top3_genres_by_year = (
    genre_by_year
    .withColumn("rank", F.row_number().over(window_spec))
    .filter(F.col("rank") <= 3) # Mantém apenas os 3 primeiros
    .drop("rank")
)
```

Figura 18 – Top 3 gêneros por ano.



Conclusão

Observa-se uma predominância consistente dos gêneros Drama, Comedy e Action ao longo de praticamente todo o período analisado, indicando que esses segmentos mantiveram forte presença na indústria cinematográfica independentemente das mudanças de mercado. Entre eles, o Drama destaca-se como o gênero mais recorrente, frequentemente ocupando a liderança em quantidade de filmes produzidos e apresentando crescimento gradual ao longo dos anos, alcançando mais de 50 produções anuais nos últimos 2 anos.

Outro aspecto relevante é a alternância entre os gêneros que ocupam as posições de destaque ao longo do tempo. Embora Drama mantenha elevada participação durante todo o período, gêneros como Action, Thriller e Adventure ganham maior representatividade em determinados anos, aproximando-se ou até superando temporariamente os demais gêneros. Esse comportamento indica mudanças nas preferências do mercado e do público consumidor, possivelmente influenciadas por tendências culturais, avanços tecnológicos e sucesso comercial de determinadas franquias cinematográficas.


Dessa forma, os resultados indicam que, embora alguns gêneros tenham mantido participação predominante durante todo o período analisado, houve variações relevantes na representatividade dos demais gêneros, refletindo a dinâmica e a constante adaptação da indústria cinematográfica às tendências de consumo e produção.

Análises sobre o dataset

Além das perguntas iniciais, o projeto realizou análises complementares.

Quantidade de gêneros por filme

Figura 19 – Gráfico candlestick.



O gráfico apresenta a distribuição da quantidade de gêneros atribuídos aos filmes ao longo do período de 2000 a 2025. Esta análise foi realizada para avaliar se a classificação de um mesmo filme em múltiplos gêneros poderia impactar significativamente as análises anteriores de volume de produção, faturamento, lucro e ROI por gênero. Observa-se que a mediana permanece estável em aproximadamente 2 a 3 gêneros por filme durante toda a série histórica, enquanto a maior parte das produções se concentra dentro desse intervalo. Além disso, a dispersão também se mantém relativamente constante ao longo do tempo, com poucos casos isolados de filmes associados a cinco, seis ou até sete gêneros.

Esses resultados indicam que a presença de múltiplos gêneros é uma característica comum e consistente do dataset, não havendo evidências de aumento significativo dessa prática ao longo dos anos. Dessa forma, embora um mesmo filme possa contribuir para mais de uma categoria nas análises por gênero, a distribuição observada sugere que esse comportamento ocorre de maneira relativamente homogênea em toda a base de dados. Consequentemente, não foram identificados indícios de que a quantidade de gêneros por filme seja suficientemente elevada ou concentrada em determinados períodos para comprometer as conclusões obtidas nas análises anteriores. Assim, os resultados reforçam a confiabilidade das comparações realizadas entre gêneros, uma vez que a estrutura de classificação dos filmes permanece estável ao longo da série histórica analisada.

Combinações de gêneros

Os pares mais frequentes identificados foram:

Figura 20 – Tabela de pares.

	A_C^B genero_1	A_C^B genero_2	1^2_3 qtd_filmes
1	Action	Adventure	349
2	Action	Thriller	325
3	Action	Science Fiction	247
4	Comedy	Family	244
5	Drama	Thriller	234
6	Crime	Thriller	219
7	Adventure	Family	219
8	Drama	Romance	218
9	Adventure	Comedy	216
10	Animation	Family	215
11	Comedy	Drama	203
12	Adventure	Fantasy	195
13	Adventure	Science Fiction	186
14	Action	Crime	178
15	Animation	Comedy	174

Com o objetivo de complementar a análise da quantidade de gêneros por filme, foi realizada uma avaliação dos pares de gêneros mais frequentes no dataset. Essa etapa buscou verificar se determinadas combinações recorrentes poderiam influenciar de forma significativa os resultados obtidos nas análises anteriores de volume de produção, faturamento, lucro e ROI por gênero.

Os resultados mostram que a associação entre gêneros é uma característica comum da base de dados, sendo os pares Action–Adventure (349 filmes), Action–Thriller (325 filmes) e Action–Science Fiction (247 filmes) os mais frequentes. Também se destacam combinações como Comedy–Family (244 filmes), Drama–Thriller (234 filmes) e Drama–Romance (218 filmes). Esses resultados indicam que diversos gêneros raramente aparecem de forma isolada, estando frequentemente associados a categorias complementares que ajudam a ampliar o apelo comercial e narrativo das produções.

Apesar dessa forte presença de filmes multigênero, a distribuição observada não sugere um problema capaz de invalidar as análises anteriores. As combinações mais frequentes envolvem diferentes gêneros e não apenas um grupo restrito de categorias, indicando que o fenômeno ocorre de maneira relativamente equilibrada em toda a base. Além disso, os resultados são coerentes com padrões conhecidos da indústria cinematográfica, como a associação entre Action e Adventure ou entre Drama e Romance, o que reforça a consistência dos dados analisados.

Dessa forma, a análise dos pares de gêneros serve como uma validação adicional da qualidade das conclusões obtidas anteriormente. Embora exista compartilhamento de filmes entre categorias devido à natureza multigênero do dataset, não foram identificadas evidências de concentrações extremas que indiquem distorções relevantes nos indicadores calculados. Consequentemente, as análises de participação dos gêneros, faturamento, lucro e ROI podem ser consideradas representativas do comportamento geral observado na base de dados.

Considerações finais

O projeto atingiu o objetivo proposto ao implementar um pipeline completo de Engenharia de Dados para análise financeira de filmes do TMDB, utilizando a arquitetura Medallion como base para organizar as etapas de ingestão, tratamento, modelagem e disponibilização dos dados. A construção das camadas Bronze, Silver e Gold permitiu preservar os dados brutos, aplicar transformações e padronizações relevantes, além de estruturar um modelo dimensional em Star Schema adequado para responder às perguntas de negócio. Com o apoio do Databricks, PySpark, Spark SQL e Unity Catalog, foi possível consolidar um ambiente analítico consistente, com tabelas fato e dimensão, controle de qualidade dos dados e maior organização para exploração das informações.

As análises realizadas demonstraram que o volume de produção por gênero não necessariamente está associado ao maior desempenho financeiro médio, já que gêneros com grande quantidade de filmes, como Drama e Comedy, apresentaram comportamento diferente de gêneros como Adventure, Animation, Science Fiction, Mystery e Horror quando avaliados por faturamento, lucro e ROI. Também foi possível observar a estabilidade da classificação multigênero ao longo do tempo e validar que as combinações de gêneros não comprometeram as conclusões obtidas. Dessa forma, o trabalho evidenciou a importância de um pipeline bem estruturado para transformar dados brutos em informação analítica confiável, permitindo compreender padrões de mercado, apoiar decisões e abrir caminho para evoluções futuras, como automação da ingestão, criação de dashboards e inclusão de análises preditivas.

Pontos de melhoria

- Integração automática com APIs da TMDB.
- Implementação de pipelines agendadas.
- Inclusão de dashboards em Power BI.
- Inclusão de métricas de avaliação, popularidade e votação.
- Análises preditivas utilizando Machine Learning.
- Monitoramento automatizado da qualidade dos dados.

Autoavaliação

Este projeto me permitiu ampliar minha visão para além das decisões técnicas esperadas na estruturação de uma arquitetura Medallion, incorporando também a perspectiva do analista e do cientista de dados. Ao longo do trabalho, passei a considerar não apenas como os dados deveriam ser organizados, mas também se as decisões de arquitetura seriam, de fato, úteis para seus usuários e para os diferentes objetivos de análise. Um exemplo disso foi a criação da tabela analítica `gold_genre_analysis`, estruturada no modelo One Big Table. Embora essa abordagem mantenha algumas redundâncias que são eliminadas pela modelagem dimensional (que é excelente para a construção de modelos semânticos, como no Power BI), ela facilita análises exploratórias e ad hoc, estudos mais

aprofundados e a preparação de dados para modelos de Machine Learning, reduzindo a necessidade de realizar múltiplos joins.

Essa experiência reforçou minha percepção de que não existe uma única arquitetura de dados que seja adequada para todos os contextos. As decisões arquiteturais precisam considerar não apenas princípios técnicos de organização, governança e eficiência, mas também o perfil dos usuários, os objetivos de negócio e analíticos e a forma como os dados serão efetivamente consumidos. Dessa forma, a arquitetura de dados deve ser entendida como uma solução moldada em torno das necessidades de seus diferentes usuários, equilibrando as boas práticas de engenharia com a utilidade prática dos dados.